SIA417 — TP n°1

Collecte et préparation des données

Consignes

— Notebook `NOM_Prenom_SIA417_TP1.ipynb`.

— Chaque question = une cellule de code *suivie* d'une cellule Markdown (2–3 lignes) expliquant la démarche et le résultat.

— Pour chaque question, indiquez la fonction utilisée et où vous l'avez trouvée (doc Pandas, Scikit-learn, etc.).

— Délai : 2 jours après diffusion.

Exercice 1 : Collecte et exploration

Option A : le fichier `data/titanic.csv` est fourni.
Option B : téléchargez-le depuis `https://raw.githubusercontent.com/mwaskom/seaborn-data/master/titanic.csv` et enregistrez-le sous `data/titanic.csv`.

1. Chargez le fichier dans un DataFrame `df`. Comparez au moins deux façons de charger un CSV en Python (par exemple `pd.read_csv`, `sns.load_dataset`, `open`). Notez celle que vous retenez et pourquoi.
2. Affichez les dimensions de `df`.
3. Affichez les 5 premières lignes.
4. Affichez le type de chaque colonne. Quelles colonnes ne sont pas numériques ?
5. Affichez les statistiques descriptives des colonnes numériques.
6. Combien de valeurs manquantes par colonne ? Quelle fonction avez-vous utilisée ?
7. Combien de doublons ?

Exercice 2 : Nettoyage

1. Listez les colonnes avec plus de 30 % de valeurs manquantes. Proposez une stratégie pour chacune (supprimer, imputer, ignorer) et justifiez.
2. Pour les colonnes avec moins de 30 % de valeurs manquantes, proposez une stratégie d'imputation. Comparez au moins deux options (moyenne, médiane, mode) et justifiez votre choix.
3. Implémentez. Supprimez les colonnes inutiles (colonnes redondantes, ou contenant directement la réponse).
4. Vérifiez qu'il ne reste aucune valeur manquante.

Exercice 3 : Transformation

1. Listez les colonnes non numériques et le nombre de valeurs distinctes de chacune.
2. Pour une colonne à 2 modalités, testez au moins deux méthodes d'encodage (`LabelEncoder`, `map`, `get_dummies`). Retenez une et justifiez.
3. Pour une colonne à 3 modalités ou plus, utilisez `pd.get_dummies`. Pourquoi certains exemples utilisent-ils `drop_first=True` ?
4. Mettez les variables numériques à la même échelle. Comparez `StandardScaler` et `MinMaxScaler` : différence, cas d'usage.
5. Implémentez. Vérifiez que la moyenne vaut ≈ 0 et l'écart-type ≈ 1 (si `StandardScaler`).

Exercice 4 : Feature engineering

1. Créez `family_size` = `sibsp` + `parch` + 1.
2. Créez `is_alone` = 1 si `family_size == 1`, sinon 0.
3. Proposez et implémentez une troisième variable de votre choix. Justifiez en 2 lignes son lien avec la survie.

Exercice 5 : Séparation X / y et train / test

1. Identifiez la variable cible (`y`) et les variables explicatives (`X`). Justifiez.
2. Séparez `X` et `y`.
3. Cherchez `train_test_split` dans la doc Scikit-learn. Découpez en 80 % entraînement / 20 % test avec `random_state=42` et `stratify=y`. Expliquez chaque paramètre.
4. Affichez les dimensions finales de `X_train`, `X_test`, `y_train`, `y_test`.